

Ciência de Dados e Aprendizagem de Máquina

✓ MANIPULAÇÃO E VISUALIZAÇÃO DE DADOS

amlucena@cruzeirodosul.edu.br


Ciência de Dados

O que é ciência de dados?


A Ciência de Dados (Data Science) é uma área **interdisciplinar** voltada para o estudo e a **análise de dados**, que visa a extração de conhecimento, **detecção de padrões** e/ou obtenção de *insights* para possíveis **tomadas de decisão**.

Áreas do Conhecimento:


- Matemática e Estatística
- Ciência da Computação
- Especialização Científica



Na última aula...



Coleta de Dados



Dados, Informação e Conhecimento

Dados são os componentes básicos a partir dos quais a informação é criada.

Informação são dados inseridos em um contexto.
Contexto é a situação que está sendo analisada.


A partir da informação vem o **conhecimento**, que permite tomar decisões adequadas, trazendo vantagem competitiva.

Dados, Informação e Conhecimento

Dados




Informação



Conhecimento



Dados, Informação e Conhecimento



Dados, Informação e Conhecimento

Um **dado** pode ser considerado como um registro mais simples, sem processamento e equiparação com outros registros, é o dado bruto de certo evento como o nome de uma pessoa ou os dados de uma venda em específico.

A **informação** já envolve a combinação de dados para prover alguma visão em um contexto um pouco maior, por exemplo o valor de um produto de uma marca comparado com de outra marca ou a totalização de vendas de um caixa.

Dados, Informação e Conhecimento

O **conhecimento** já contextualiza de forma ainda mais abrangente a informação com o cruzamento de outros fatos internos ou externos à organização ou problema, como o aumento de vendas por conta das mais variadas causas: feriados, visita de turistas à cidade ou outros.

Em geral, há no conhecimento alguma análise crítica e cooperação com nossa habilidade humana de correlacionar fatos.

Coleta de Dados


Suponha que você foi contratado como analista na expectativa de aumentar as vendas de uma pizzeria.

Quais dados você coletaria?




Coleta de Dados

Pode ser tão simples quanto medir objetos, fazer questionários, contar pessoas que passam por uma avenida, **ou um pouco mais complexo...**



Dados: Qualitativo vs Quantitativo

Dados são uma coleção de fatos, como números, palavras, medidas, observações ou apenas descrições de coisas.



Dados: Qualitativo vs Quantitativo

Exemplos:

Qualitativo: (Categórico)

- O destino de férias favorito dos seus amigos
- Os nomes mais comuns na sua cidade.
- Como descrever o cheiro de um novo perfume.

Quantitativo: (Numérico)

- Altura (contínuo)
- Peso (contínuo)
- Pétalas em uma flor (discreto)
- Clientes em uma loja (discreto)

Análise Exploratória de Dados

Após a coleta, antes de pensarmos em aplicar modelos complexos, uma etapa importante é conhecer o conjunto de dados obtido. Fazer uma análise de forma à explorar suas características e como os dados se relacionam.


A **Análise Exploratória de Dados** (*Exploratory Data Analysis EDA*) é usada para analisar e investigar conjuntos de dados e resumir suas principais características, muitas vezes empregando métodos de **visualização de dados**.



Análise Exploratória de Dados

Geralmente aplicada preliminarmente, esta etapa envolve analisar e visualizar dados para entender suas principais características, descobrir padrões e identificar relacionamentos entre variáveis.


Refere-se ao método de estudar e explorar conjuntos de registros para apreender suas características predominantes, descobrir padrões, localizar *outliers* e identificar relacionamentos entre variáveis.



Análise Exploratória de Dados

Alguns aspectos principais incluem:

- **Distribuição de dados:** intervalo, tendências centrais (média, mediana) e dispersão.
- **Representações gráficas:** gráficos de dispersão, barras, linhas
- **Deteção de Anomalias (outliers):** valores incomuns que se desviam de outros pontos de dados.
- **Análise de correlação:** relacionamentos entre variáveis, como afetam umas às outras.
- **Lidar com valores ausentes.**
- **Estatísticas resumidas.**



Visualização de Dados








Visualização de dados é a **representação gráfica** de informações e dados. Ao usar elementos visuais como tabelas, gráficos e mapas, as ferramentas de visualização de dados fornecem uma maneira acessível de ver e entender tendências, outliers e padrões em dados.



Visualização de Dados

Principais tipos de gráficos:

- Linhas;
- Barras;
- Histogramas;
- Dispersão;
- Setores (pizza);
- Geográfico;
- Árvores/Grafo;



Variáveis Qualitativas

Variáveis Qualitativas

Tabela de Frequência

A Apple Computer lançou o iMac em agosto de 1998 e queria saber se o novo produto estava conquistando novos clientes.

A principal dúvida era se o iMac atrairia apenas proprietários de Macs mais antigos ou se expandiria o mercado para a Apple.

Para investigar, a empresa realizou uma pesquisa com 500 clientes que compraram o iMac.

Os entrevistados foram classificados em três grupos: antigos proprietários de Macintosh, antigos proprietários de Windows e novos compradores de computadores.

Computador anterior	Frequência	Frequência Relativa
Nenhum	85	0,17
Windows	60	0,12
Macintosh	355	0,71
Total	500	1,00

Variáveis Qualitativas

Gráfico de Setores (Pizza)

Em um gráfico de pizza, cada categoria é representada por uma fatia da pizza.

A área da fatia é proporcional à porcentagem de respostas na categoria.

Gráficos de pizza são eficazes para exibir as frequências relativas de um pequeno número de categorias.

EMBORA A MAIORIA DOS COMPRADORES DE IMAC FOSSEM PROPRIETÁRIOS DE MACINTOSH, A APPLE FOI ENCORAJADA PELOS 12% DE COMPRADORES QUE ERAM EX-USUÁRIOS DO WINDOWS E PELOS 17% DE COMPRADORES QUE ESTAVAM COMPRANDO UM COMPUTADOR PELA PRIMEIRA VEZ.




Figura 1. Gráfico de pizza de compras de iMac ilustra frequências de posse anterior de computadores.




Variáveis Qualitativas

Gráfico de Setores (Pizza) - Desvantagens

No entanto, não são recomendados quando se tem um grande número de categorias.

Gráficos de pizza também podem ser confusos quando usados para comparar os resultados de duas pesquisas ou experimentos diferentes.

Se eles forem baseados em um pequeno número de observações, pode ser enganoso rotular as fatias da pizza com porcentagens.



Variáveis Qualitativas

Gráfico de Barras

Gráficos de barras também podem ser usados para representar frequências de diferentes categorias.

Um gráfico de barras das compras de iMacs é mostrado na Figura 2.

As frequências são mostradas no eixo Y e o tipo de computador que você já teve é mostrado no eixo X.

Normalmente, o eixo Y mostra o número de observações em cada categoria, em vez da porcentagem de observações, como é típico em gráficos de pizza.




Figura 2. Gráfico de barras de compras de iMac em função da posse anterior de computadores.

Variáveis Qualitativas

Gráfico de Barras

Não exagere! Às vezes, as pessoas adicionam recursos aos gráficos que não ajudam a transmitir as informações.

Por exemplo, gráficos de barras tridimensionais, como o mostrado na Figura 4, geralmente não são tão eficazes quanto seus equivalentes bidimensionais.




Figura 4. Uma versão tridimensional da Figura 2.

Variáveis Quantitativas

Variáveis Quantitativas

Gráfico de Barras

Os gráficos de barras são particularmente eficazes para mostrar mudanças ao longo do tempo.

A Figura 3, por exemplo, mostra o aumento percentual do Índice de Preços ao Consumidor (IPC) em quatro períodos de três meses.

A flutuação da inflação é evidente no gráfico.




Figura 3. Variação percentual do IPC ao longo do tempo. Cada barra representa o aumento percentual nos três meses encerrados na data indicada.

Variáveis Quantitativas

Histograma

Um histograma é um método gráfico para exibir o formato de uma distribuição.

É particularmente útil quando há um grande número de observações.

Começamos com um exemplo que consiste nas notas de 642 alunos em um teste de psicologia.

O teste consiste em 197 itens, cada um classificado como "correto" ou "incorreto". As notas dos alunos variaram de 46 a 167.

Limite inferior do intervalo	Limite superior do intervalo	Frequência de aula
39,5	49,5	3
49,5	59,5	10
59,5	69,5	53
69,5	79,5	107
79,5	89,5	147
89,5	99,5	130
99,5	109,5	78
109,5	119,5	59
119,5	129,5	36
129,5	139,5	11
139,5	149,5	6
149,5	159,5	1
159,5	169,5	1

Variáveis Quantitativas

Em um histograma, as frequências de classe são representadas por barras. A altura de cada barra corresponde à sua frequência de classe. Um histograma desses dados é mostrado na Figura 1.




Figura 1. Histograma de pontuações em um teste de psicologia.

O histograma deixa claro que a maioria das pontuações está no meio da distribuição, com menos pontuações nos extremos. Você também pode ver que a distribuição não é simétrica: as pontuações se estendem mais para a direita do que para a esquerda.

Variáveis Quantitativas

Gráfico de Linha

Um gráfico de linhas é um gráfico de barras com os topos das barras representados por pontos unidos por linhas (o restante da barra é suprimido).




Figura 1. Gráfico de barras da variação percentual do IPC ao longo do tempo. Cada barra representa o aumento percentual nos três meses encerrados na data indicada.




Figura 2. Gráfico de linhas da variação percentual do IPC ao longo do tempo. Cada ponto representa o aumento percentual nos três meses encerrados na data indicada.


Variáveis Quantitativas

Polígonos de Frequência

Gráficos de linhas são apropriados apenas quando os eixos X e Y exibem variáveis ordenadas (em vez de qualitativas).

Embora gráficos de barras também possam ser usados nessa situação, gráficos de linhas geralmente são melhores para comparar mudanças ao longo do tempo.

Vale lembrar que é enganoso usar um gráfico de linhas quando o eixo X contém apenas variáveis qualitativas.




Variáveis Quantitativas

Polígonos de Frequência

Polígonos de frequência são um recurso gráfico para compreender as formas das distribuições.

Eles têm a mesma finalidade dos histogramas, mas são especialmente úteis para comparar conjuntos de dados.

Um polígono de frequência para 642 pontuações de testes de psicologia mostrados na Figura 1 foi construído a partir da tabela de frequência mostrada na Tabela 1.




Variáveis Quantitativas

Gráfico de Pontos ou Dispersão (Scatter)

Diagramas de pontos podem ser usados para exibir vários tipos de informações.

O gráfico de pontos ao lado mostra o número de pessoas jogando vários jogos de cartas no site do Yahoo em uma quarta-feira.

Este gráfico facilita a comparação da popularidade dos jogos separadamente nos dois dias, mas não facilita a comparação da popularidade de um determinado jogo nos dois dias.



Variáveis Quantitativas

Gráfico de Pontos ou Dispersão (Scatter)

O gráfico de pontos na Figura 4 facilita a comparação dos dias da semana para jogos específicos, ao mesmo tempo em que retrata as diferenças entre os jogos.




Figura 4. Uma maneira alternativa de mostrar o número de pessoas jogando vários jogos de cartas em um domingo e em uma quarta-feira.

Escolhendo gráficos e cores

A escolha adequada do gráfico mais aderente à natureza dos dados e ao propósito de visualização requer um bom conhecimento das estratégias possíveis de visualização, bem como entender a organização dos dados existentes em um dataset.

- **Pergunte-se:** *O que você está tentando comunicar com seus dados? Qual é a história que você quer contar?*
 - Variação de uma medida ao longo do tempo? Linhas...
 - Comparar magnitudes ou grandezas? Barras..
 - Mostrar as partes de um todo? Setores...
 - Correlações? Dispersão...

Confira o material: <https://raw.githubusercontent.com/ft-interactive/chart-doctor/master/visual-vocabulary/poster.png>

Escolhendo gráficos e cores

A cor é um fator importante na criação dos gráficos. Um bom conjunto de cores destacará a história que você quer que os dados contem, enquanto um conjunto ruim esconderá ou distrairá do propósito de uma visualização.

É importante conhecer:

- Diferentes padrões, como RGB e HSL
- Conceito de paleta
- Conceitos de matriz (hue) e luminosidade





SlideRabbit

Tipos de paleta de cores

Paleta Qualitativa




Uma paleta qualitativa é usada quando a variável é categórica por natureza. Variáveis categóricas são aquelas que assumem rótulos distintos sem ordenação inerente. Exemplos incluem país ou estado, raça e gênero. Cada valor possível da variável recebe uma cor de uma paleta qualitativa.





Tipos de paleta de cores

Paleta Sequencial



Quando a variável atribuída é numérica ou tem valores ordenados, ela pode ser representada com uma paleta sequencial. As cores são atribuídas a valores de dados em de forma contínua, geralmente com base na luminosidade, matiz ou ambos.

New Revenue




Tipos de paleta de cores

Paleta Divergente



Se a variável numérica tiver um valor central significativo, como zero, então podemos aplicar uma paleta divergente. Uma paleta divergente é uma combinação de duas paletas sequenciais com um ponto compartilhado no valor central. Valores maiores que o centro são atribuídos a cores em um lado do centro, enquanto valores menores são atribuídos a cores no lado oposto.




Contínuo vs Discreto




Paletas sequenciais e divergentes podem ser associadas a valores de dados de duas maneiras diferentes: como um conjunto discreto de cores, cada uma associada a um intervalo numérico, ou como uma função contínua entre valor numérico e cor.

2010 US Population




2010 US Population



Algumas sugestões...

1. Evite o uso desnecessário de cores
2. Seja consistente com as cores em todos os gráficos
3. Aproveite o significado da cor
4. Acessibilidade e Atender ao daltonismo



Ferramentas:

ColorBrewer

<https://colorbrewer2.org/#type=sequential&scheme=BuGn&n=3>

Data Color Picker

<https://www.learnui.design/tools/data-color-picker.html>

